StarGAN: Unified Generative Adversarial Networks for Multi-Domain Image-to-Image Translation

2018/9/14 王诺

最近的研究表明两个域之间的图像转换取得了显着的成功。然而,现有方法在处理两个以上域时具有有限的可扩展性和鲁棒性,只能对每两个域之间的图像转换构建独立的模型。 为解决这一限制,本文作者提出了 StarGAN,这是一种新颖且可扩展的方法,可以使用单个模型对多个域执行图像到图像的转换。 StarGAN 的这种模型架构允许在单个网络内同时训练含有多个域的多个数据集。与现有模型相比, StarGAN 具有更好的图像质量,并且可将输入图像灵活地转换为任何所需目标域的图像。 文章中通过实验证明了所提出的方法在面部属性转移和面部表情转移等任务方面的有效性。

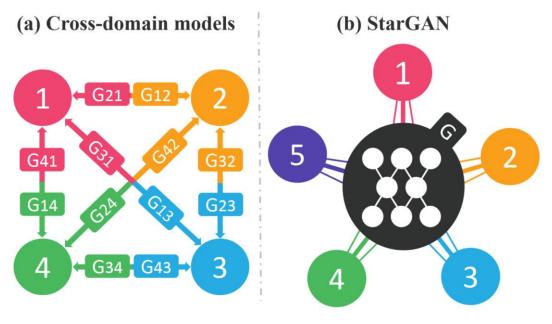


图 1

图 1 展示了本文提出的网络架构 StarGAN 的功能特点。相比于左图传统方法 (为实现四个域的两两之间图像转化,需要训练 12 个网络模型),右图的 StarGAN 只需要训练一次即可实现五个域的两两之间图像转换。作者提出这个模 型来源于不同域之间仍存在许多不变的特性,如本文进行了任务不同表情之间的 图像转换,多于不同的表情,人的脸型、皮肤的颜色等信息是不变的,使用多个 域的数据集训练网络,更有利于网络学习变量与不变量。

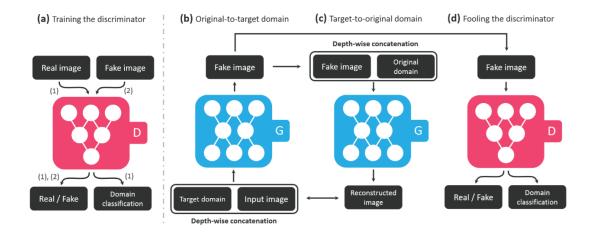


图 2

图 2 展示了 StarGAN 的详细架构,它包含一个鉴别器和一个生成器。其中鉴别器 D 不仅具有判定图像是否是真实图像的功能,也可以判定图像所属域。其中对真实图像的域判定用于优化鉴别器 D,对虚假图像的域判定用于优化生成器 G;生成器的输入是经过加标签处理的图像,训练过程中标签的类别是随机选择的。为了更好地优化生成器,输出的图像会在添加原图像所在域的标签后作为生成器的输入,此时的输出图像理想情况下应与原图像一致。

$$\mathcal{L}_D = -\mathcal{L}_{adv} + \lambda_{cls} \, \mathcal{L}^r_{cls},$$
 $\mathcal{L}_G = \mathcal{L}_{adv} + \lambda_{cls} \, \mathcal{L}^f_{cls} + \lambda_{rec} \, \mathcal{L}_{rec},$

图 3 分别展示了鉴别器 D 和生成器 G 的损失函数。其中 L_{adv} 代表对抗性损失(此处的对抗性损失并非一般 GAN 中的定义,而是使用了 Wasserstein GAN,该网络可实现高分辨率的输出,会对提出该网络的文章阅读后会在笔记中做详细介绍); L_{cls} 代表域分类损失,上一段有详细介绍; L_{rec} 为第二次输出和原图像之间的一致性损失。

Mask Vector. To alleviate this problem, we introduce a mask vector m that allows StarGAN to ignore unspecified labels and focus on the explicitly known label provided by a particular dataset. In StarGAN, we use an n-dimensional one-hot vector to represent m, with n being the number of datasets. In addition, we define a unified version of the label as a vector

$$\tilde{c} = [c_1, ..., c_n, m],$$
(7)

图 4

图 4 介绍了文章中为实现不同数据集之间的域转换(如本文实验中用到的两个数据集,一个数据集中的数据根据头发颜色、皮肤颜色、年龄等属性进行域分类,而另一个数据集根据表情进行域分类),因为一个数据集中的数据不含另一个数据集中的相关分类标记,作者通过引入 Mask Vector 解决该问题,本质即将域标签设定为含有多个向量的数组,向量的个数域与数据集的个数相同,每个向量代表对应数据集的相关域标记,对于未知的域标记信息,用 0 表示。

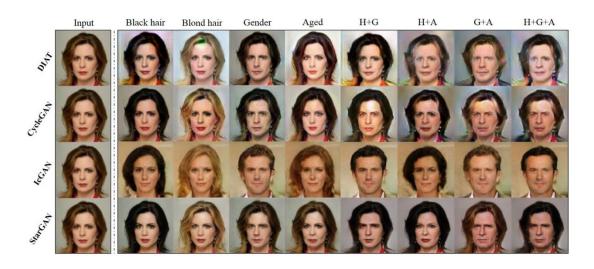


图 5

图 5 展示了使用各种 GAN 网络进行域转换的实验结果,可以明显看出本文提出的 starGAN 生成的图像效果更好。(但本人认为效果好的很大一部分原因是因为引用了 Wasserstein GAN 的损失函数,实验了生成高分辨率图像。)